

基于情境感知的网络谣言早期 检测方法研究*

杨玉珍^{1,2} 王 坤² 王晓阳² 刘文锋^{1,2}

(1.菏泽学院计算机学院 菏泽 274100;
2.临沂大学信息科学与工程学院 临沂 276000)

摘要: [研究目的] 现有网络谣言检测方法多依靠情感特征、语法特征、外部知识等信号来验证信息的真伪,具有滞后性,提出一种基于情境感知的网络谣言检测方法,以应对网络谣言早期检测的需要。[研究方法] 该方法利用拉普拉斯谱聚类完成领域内和领域间的话题情境聚类,依据领域内和领域间的话题分布,构建四个话题情境,用于捕捉话题的热度和新颖度;并融合新闻文本、风格特征、情感等特征设计一个谣言情境感知模型。[研究结果/结论] 通过在中文数据集 Ch-9 和英文数据集 En-3 的实验验证,结果显示该方法均高于基础模型,验证了话题情境可以增强证据,有利于谣言的早期发现。

关键词: 网络谣言; 谣言检测; 情境感知; 谱聚类; 领域内; 领域间

中图分类号: G206.3

文献标识码: A

文章编号: 1002-1965(2025)01-0112-09

引用格式: 杨玉珍, 王 坤, 王晓阳, 等. 基于情境感知的网络谣言早期检测方法研究[J]. 情报杂志, 2025, 44(1): 112-120, 50.

DOI: 10.3969/j.issn.1002-1965.2025.01.015

Research on Early Detection Method for Online Rumors Based on Situational Awareness

Yang Yuzhen^{1,2} Wang Kun² Wang Xiaoyang² Liu Wenfeng^{1,2}

(1.School of Computer Science, Heze College, Heze 274100;

2.School of Information Science and Engineering, Linyi University, Linyi 276000)

Abstract: [Research purpose] Existing online rumor detection methods mostly rely on signals such as emotional features, grammatical features, and external knowledge to verify the authenticity of the information, which has a lagging effect. This paper proposes a rumor detection method based on situational awareness to cope with the need of early detection of online rumors. [Research method] The approach employs Laplacian spectral clustering to perform topic contextual clustering within and across domains. Based on the topic distributions within and across domains, four topic contexts are constructed to capture the popularity and novelty of the topics. Subsequently, a rumor context-aware model is designed by integrating features from news text, stylistic elements, and sentiment. [Research result/conclusion] Through experimental validation on the Chinese dataset Ch-9 and the English dataset En-3, the results show that the method is higher than the base model, which verifies that topic context can enhance the evidence and facilitate the early detection of rumors.

Key words: Internet rumor; rumor detection; context-awareness; spectral clustering; intra-domain; inter-domain

0 引言

网络谣言快速、不受限制的传播已成为全球社会

问题,并造成了严重后果,如损害公共健康、负面影响环境保护、实施经济操纵、造成信任危机等。再加上人工智能在计算机视觉的生成模型和自然语言处理的生

收稿日期: 2024-08-12

修回日期: 2024-09-13

基金项目: 山东省社会科学规划基金项目“面向公共安全事件的重大舆情引导机制研究”(编号: 20CDCJ01)研究成果。

作者简介: 杨玉珍, 女, 1978 年生, 博士, 副教授, 研究方向: 自然语言处理、多模态数据分析、虚假信息检测等; 王 坤, 男, 1997 年生, 硕士研究生, 研究方向: 自然语言处理研究; 王晓阳, 男, 1998 年生, 硕士研究生, 研究方向: 自然语言处理研究; 刘文锋, 男, 1978 年生, 博士, 副教授, 研究方向: 自然语言处理、虚假信息检测等。

成模型方面取得的巨大进步,大大降低了信息的生成成本,进一步助长了网络谣言的泛滥。为了缓解网络谣言带来的恶劣影响,谣言的自动检测一度成为研究者们关注的焦点。

现有检测方法聚焦于帖子内容,通过匹配帖子内容与评论信息的语义一致性来鉴定信息的真伪^[1],或检索外部数据源作为谣言检测的证据^[2]。事实上,随着人工智能生成技术的成熟,单纯地通过单词、句子、文本结构等特征难以作为谣言检测的唯一证据,再加上谣言的产生、发酵到广泛传播需要一个时间段才能完成,作为证据的外部数据源具有滞后性,显然现有方法已不能满足网络谣言早期检测的需要。本文通过研究发现,现有方法多关注的是显式的证据,是不是存在隐式证据呢?基于这个想法,本文调研了谣言的产生动机,发现谣言具有认知上的钩子作用,发布的信息更具有吸引力,能够在短时间内引起读者的心理反应,其内容具有焦点性和新奇性,换句话说,多数谣言的产生往往与其同时期的主流舆论和用户关注的热点相关。基于这个思路,本文提出一种基于情境感知的网络谣言早期检测方法,该方法中首先通过谱聚类获取宏观情境空间,找出热点主题,再依据同时期内容热点主题构建不同主题领域内和领域间的微观情境,最后融合新闻文本、风格特征、情感等特征设计一个情境感知模型,用于虚假信息早期检测。

1 相关研究

谣言检测旨在确定信息的真实性,现有检测方法大致分为基于内容的方法和基于上下文的方法两类。

基于内容的方法完全依赖信息内容,有的研究者认为评论信息也属于帖子内容的一部分^[3]。该类方法大多通过提取文本表示^[4]、情感信息^[5]、写作风格^[6]等信息确定信息的可信度,并取得了不错的效果。随着深度学习研究的深入,其强大的特征描述能力吸引了研究者们注意。曾江峰等利用 BERT 挖掘文本中动态的语义特征,融合主题特征构建谣言检测模型^[7]。Ma 等^[8]将微博的上下文视为长度可变的时间序列,按照一定的时间间隔进行划分,并用 GRU 对其进行建模。然而,随着谣言传播时间的推移,用户的评论信息可能随时间的变化而发生变化,因此 Chen 等^[9]引入注意力机制,用于有选择性地捕捉连续帖子的时间隐藏表征。为了解决海量数据处理迟滞的问题,王昊等^[10]将情感和图片特征引入 BERT 虚假信息检测模型,证明在模型训练充分的基础上,能够更好地提升虚假信息识别性能。安全等^[11]选取 TextCNN 作为专家模型,获取谣言文本特征,采用门控网络结构聚合专家组特征实现谣言特征的个性化学习。上述方法的性能依

赖于从原始文本中提取的统计特征,忽略了特征之间的语义联系。为了解决这一问题,Kaliyar 等^[12]提出一种 FakeBERT 虚假新闻检测模型,该模型将不同大小的核和滤波器单卷积神经网络与 BERT 结合,有效的解决了信息中的歧义问题。

上述谣言检测方法是从新闻及其回复中寻找证据用于谣言检测,实际上大多数证据是在谣言爆发一段时间后才不断浮出水面,在证据稀缺的情况下难以应对谣言的早期检测。为了应对谣言早期检测数据源稀缺问题,小样本学习和零样本学习纷纷被引入谣言检测中。Wu 等^[13]提出一种“提示和对齐”的假新闻检测新范式,这种方法将新闻文章包装成与任务相关的文本提示来减轻标注数据的稀缺性,并利用预训练模型中的知识和社会背景拓扑获取特定的任务知识,取得少样本学习的进步。Li 等^[14]使用预训练和微调的方法,构建立场增强的谣言提示模板,作为谣言文本形成上下文的线索,在零样本学习谣言检测任务上取得了较好的效果。研究者也在多模态数据源中寻找谣言检测的证据,用于网络谣言检测^[15],同样也取得不错的结果。

基于上下文的谣言检测方法是指通过捕捉新闻出现、发布和传播特征来确定新闻来源、新闻发布者、新闻接收者的可信度等信息综合评估信息的可信度^[16]。也有研究者将上下文信息定义为影响谣言传播的主要因素,像 Lin 等^[17]将社交媒体上流传的谣言表示为不同的传播线程,然后设计一种分层提示编码机制,为提示和谣言数据学习与语言无关的上下文表示。汪子航等^[18]从传播结构和传播节点属性两个维度训练基于残差图卷积神经网络谣言检测模型。由于神经网络缺乏可解释性,Zhang 等^[19]的研究发现传播网络中存在大量与任务无关的节点边,他们通过限制事件子图的方式发现反事实证据,并通过实验证明了利用关键子图进行谣言检测的多视角解释问题。为了对抗信息传播过程带来的噪声,朱贺^[20]提取传播结构特征和时序依赖特征作为对抗神经网络的输入,产生虚拟声音以便增强模型对“噪声”的容错能力。值得说明的是谣言的传播结构形成以及网民之间的互动证据的生成均需要一个较长的时间期,这便给基于上下文的谣言检测方法带挑战。

综上,无论是基于内容的方法还是于基于上下文的方法都面临证据迟滞的问题,不利用于谣言的早期检测。为了解决这一问题,本文通过定义谣言情境,旨在利用文章发表时阅读新闻的“氛围”检测可能存在谣言。本文思路与 Sheng 等^[21]提出的 Zoom out 方法类似,不同于 Zoom out 仅关注于单一维度的相似性的是,我们关注谣言主题情境和报道的发展趋势,从整体

上把握谣言的主题分布和情境感知。

2 基于情境感知的谣言早期检测方法

2.1 模型定义

本文提出的基于情境感知的谣言早期检测模型如图1所示。

不同于现有模型的是,基于情境感知的谣言感知

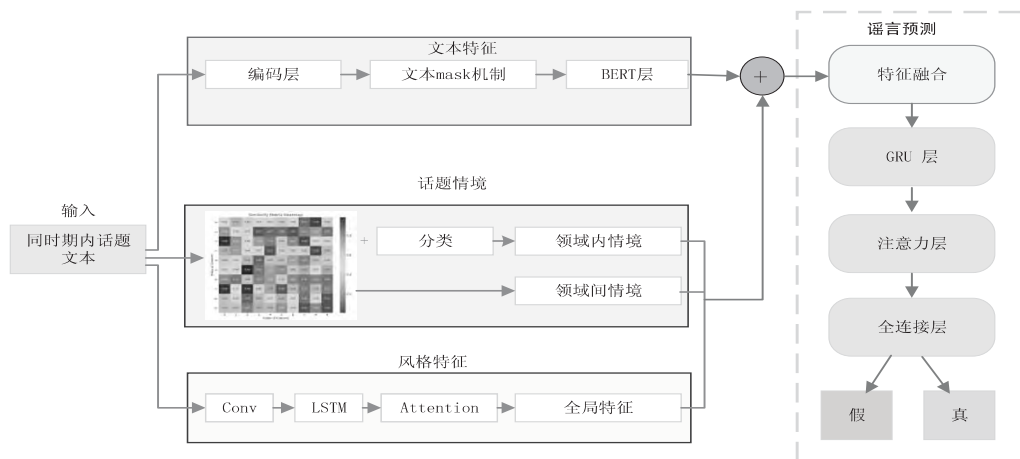


图1 基于情境感知的谣言早期检测模型

话题情境构建与捕捉是本文的重点,这里借鉴了文献[21]的研究思路,如果一个话题相较于同时期的话题具有新颖性,它应表现为一个离群点。因此,本文首先对某一时间段信息聚类,得到各领域的不同话题。为了得到话题的热度和新颖度,这里将数据划分为单领域和多领域,用于捕捉领域内热点话题和新颖话题,同时与不同领域话题相匹配,获取领域间话题的热度和新颖度,谣言情境构建具体过程将在2.2节介绍。在基于风格的特征抽取中借鉴了文献[22]的方法,首先将输入数据输入卷积神经网络,再经过一个LSTM层,最后通过注意力机制得到一个全局风格特征。

在谣言预测阶段,将得到文本特征、风格特征与话题情境融合作为GRU(Gated Recurrent Unit, GRU)层的输入,再经过一个注意力层,达到网络谣言早期检测的目的。

2.2 基于拉谱拉期聚类的谣言全局情境感知

为了感知话题全局情境,我们这里采用拉谱拉斯聚类的方式实现话题领域内和领域间的聚类。下面详细介绍本方法。

定义 $N = \{p_i | i \in \{1, 2, \dots, n\}\}$ 为一个领域内所有新闻发表的收集项的集合。对原始新闻文本数据进行清洗和预处理,利用预训练的BERT模型将预处理后的新闻文本 p_i 转换为 P_i , P_i 词向量捕获了原始文本的语义信息,为后续的相似度计算和聚类分析提供基础。计算每个新闻条目 P_i 与其他所有新闻条目 P_j 之间的余弦相似度,其相似度矩阵定义如公式(1)所示:

模型按时间序列捕捉话题情境、文本特征和风格特征。本文模型由文本特征、风格特征、话题情境及谣言预测四部分构成。其中文本特征与现有研究方法类似,包括对语言特征、语义特征以及情感特征的抽取和融合,具体先对上述特征编码,经过一个mask机制,最后通过BERT模型实现文本特征的抽取与融合。

$$s(P_i, P_j) = \frac{P_i \cdot P_j}{\|P_i\| \|P_j\|} \quad (1)$$

假设新闻条目向量集合为 $\{P_1, P_2, \dots, P_n\}$, 相似度矩阵 S 可以表示为公式(2):

$$S = \begin{pmatrix} s(P_1, P_1) & \cdots & s(P_1, P_n) \\ \vdots & \ddots & \vdots \\ s(P_n, P_1) & \cdots & s(P_n, P_n) \end{pmatrix} \quad (2)$$

为了降低对角线元素的影响,将对角线元素替换为去除对角线元素的每列的平均值,对于矩阵 S 中的每一列,对角线元素 s_{ii} 被替换为公式(3):

$$s_{/ii} = \frac{\sum_{j=1, j \neq i}^n s_{ji}}{n-1} \quad (3)$$

其中, n 是列中元素的数量, s_{ji} 是第 j 行第 i 列的元素,替换之后的矩阵 S_{new} 可以表示为公式(4):

$$S_{new} = \begin{pmatrix} s_{/11} & \cdots & s(P_1, P_n) \\ \vdots & \ddots & \vdots \\ s(P_n, P_1) & \cdots & s_{/nn} \end{pmatrix} \quad (4)$$

对于度矩阵 D 中的每个元素 d_{ij} 可定义为相似度矩阵 S_{new} 第 i 行的和,定义为公式(5)。

$$d_{ij} = \sum_j s_{new ij} \quad (5)$$

经过上述定义,拉普拉斯矩阵可被定义为 $L = D - S_{new}$,为了降低节点度数分布不均匀的问题,进一步对标准的拉普拉斯矩阵归一化,归一化的矩阵可被转化为公式(6)。

$$\tilde{L} = I - D^{-\frac{1}{2}} S_{new} D^{-\frac{1}{2}} \quad (6)$$

经过特征分解计算出拉普拉斯矩阵 L 的特征值和对应的特征向量,如公式(7)所示。

$$Lv = \lambda v \quad (7)$$

特征向量将数量点映射到低维空间。使用特征向量形成新的特征空间,选择与最小特征值对应的 k 个特征向量,将这些特征向量排列成新的矩阵。在由选定的特征向量张成的新空间中,使用标准 k -means 聚类技术来生成最终的聚类伪标签,可定义为:

$$clusters = k - means(v_1, v_2, \dots, v_k) \quad (8)$$

2.3 领域内与领域间话题情境定义

为了定义领域内和领域间话题情境,我们假设存在单领域数据集 Env^S 和多领域数据集 Env^D ,其中单领域数据集可被定义为公式(9):

$$Env^S = \{n_i \mid n_i \in S_j, 0 < t_{n_i} \leq T\} \quad (9)$$

这里 S_j 为领域标签, n_i 为领域 S_j 中某一时间段 T 内发布的信息条数。

多领域数据集 Env^D 可定义为:

$$Env^D = \{(n_{1j}, n_{2j}, \dots, n_{kj}) \mid n_{ij} \in S_1, S_2, \dots, S_k, 0 < t_{n_{ij}} \leq T\} \quad (10)$$

这里 S_j 为领域标签, n_{ij} 为领域 S_j 在时间段 T 内发布的信息条数,显然 Env^D 中信息条数为时间段 T 发布信息的总数目。

领域内话题情境由领域集合 Env^S 经过拉普拉斯谱聚类得到。需要说明的是,领域内话题情境集合可能包含多个话题,这里把同一领域不同的话题集合定义为 $cluster^s$ 。同样,在领域间话题情境 Env^D 中,也包含了不同的话题,本文将领域间的不同话题集合定义为 $cluster^m$ 。通过上述定义每条信息可能分布领域内,也可能分布领域间,显然,当信息同属于领域内和领域间同一话题时,信息含量最大,因此,本文将信息的话题情感定义为公式(11)-(14)四个集合。

$$Env_1^S = \{(n_{1j}, n_{2j}, \dots, n_{kj}) \mid n_{ij} \in Env^S, clusters_s = c_1\} \quad (11)$$

$$Env_2^S = \{(n_{1j}, n_{2j}, \dots, n_{kj}) \mid n_{ij} \in Env^S, clusters_s = c_2\} \quad (12)$$

$$Env_3^S = \{(n_{1j}, n_{2j}, \dots, n_{kj}) \mid n_{ij} \in Env^S, clusters_s = c_3\} \quad (13)$$

$$Env_4^S = \{(n_{1j}, n_{2j}, \dots, n_{kj}) \mid n_{ij} \in Env^S, clusters_s = c_4\} \quad (14)$$

为了便于描述,这里定义话题覆盖度 c_i ,其中 $i \in \{1, 2, 3, 4\}$ 。其中 c_1 表示新闻为领域 $cluster^s$ 某一话题,同时该话题与领域间话题 $cluster^m$ 具有较高相似度,此类话题热度最高。 c_2 表为领域 $clusters_s$ 某一话题,而与领域间话题 $cluster^m$ 相似度小于一个阈值,它属于领域间话题的一个离群点,这类话题具有单领域热度,多领域新颖度; c_3 表示新闻在领域内是一个离群点,却

出现在多领域某一话题集合 $cluster^m$,也说明了该新闻具有话题新颖度,同时也说明该话题属于关联性话题,是某一领域话题的外延; c_4 则表示新闻无论多领域还是单领域都是离群点,话题情境对此类话题影响较小,基本不具有参考性。

2.4 基于情境感知的谣言预测

在基于情境感知的谣言早期检测模型中,我们定义多领域训练集合 $D_{tr} = \{(p_i, c_i, y_i)\}_{i=1}^{N_{tr}}$,其中 N_{tr} 是训练数据的数量, p_i 是新闻正文, c_i 是领域类别, $y_i \in \{1, 0\}$ 表示该新闻的标签,其中 $y_i = 1$ 为谣言, $y_i = 0$ 为非谣言。

经过谣言情境感知,我们获取了文本特征、情境特征以及风格特征,这里我们采用拼接的方法实现特征融合,接下连接一个 GRU 层,如公式(15):

$$H_i = GRU(P_i) \quad (15)$$

其中 $GRU(\cdot)$ 为时序特征 GRU 函数, P_i 为上一层输出。

为接下来连接一个注意力机制用于捕捉新颖度和热度高的话题,如公式(16)所示:

$$H_{i+1} = Attention(H_i, m_i) \quad (16)$$

其中 $Attention(\cdot)$ 为函数, H_i 为上一层输出, m_i 是新闻正文的注意力 mask, $Attention$ 运算的数学表示如下:

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (17)$$

最后将其输入一个全连接层用于谣言的预测。

在模型训练中我们采用如公式(18)所示交叉熵作为损失函数。

$$BCELoss = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (18)$$

其中, N 为样本总数, y_i 是第 l 个样本的真实标签,取值为 0 或者 1。 \hat{y}_i 是模型对第 l 个样本的预测概率,取值在区间(0,1)内。

3 实验

为了验证本文方法的可行性,我们通过实验回答以下几个问题:

EQ1:话题情境可以有效提高假新闻检测模型的性能吗?

EQ2:基于情境感知的方法效果如何?

EQ3:参数设置为多少时模型可以达到最佳效果?

3.1 数据集

我们使用 Zhu 等人^[23]整合后的多领域数据集 Ch-9。该数据集是从新浪微博收集的中文多领域假新

闻检测数据集,源自 2014 年 12 月至 2021 年 3 月之间的新闻报道,包含 4 488 条虚假新闻和 4 640 条真实新闻,涵盖 9 个领域分别是科学、军事、教育、灾害、政治、健康、金融、娱乐和社会。使用该数据集的原因主要包含以下两点:①该数据集不仅包含单一领域的新闻,还整合了多个领域的新闻。这种多视角和多领域的整合有助于我们构建领域间和领域内话题情境;②该数据集是现有公开的、并被证明有效的数据集。数据集分布如表 1 所示:

表 1 数据集 Ch-9 数据分布

领域	真信息	谣言	共计
科学	143	93	236
军事	121	222	343
教育	443	48	491
灾害	185	591	776
政治	306	546	852
健康	485	515	1 000
经济	959	362	1 321
娱乐	1 000	440	1 440
社会	1 198	1 471	2 669
总计	4 840	4 288	9 128

此外,我们还使用了英文数据集 En-3^[24],该数据集结合 FakeNewsNet 数据集^[25]和 COVID 数据集^[26],形成的英文多领域假新闻检测数据集,共包含真新闻 22 001 条和 6 763 条虚假新闻,涵盖三个领域分别是 PolitiFact 政治新闻、GossipCop 名人八卦和 COVID-19 数据,见表 2。

表 2 数据集 En-3 数据分布

数据集	真信息	谣言	合计
GossipCop	16 804	5 067	21 871
PolitiFact	447	379	826
COVID	4 750	1317	6 067
总计	22 001	6 763	28 764

3.2 基线和指标

由于不同领域新闻环境中测试集和验证集数据分布可能不同,存在数据不平衡问题,我们使用 AUC、召回率、精确率、准确率以及 F_1 值作为评价指标,全面评估模型性能。

我们选择了 8 种基于内容的方法和 2 种基于外部知识的方法作为基准模型。模型和基准模型使用特征分布情况如表 3 所示。

3.2.1 基于内容的方法

BERT 模型^[27]:用于中文和英文文本分类任务的 BERT 模型,使用了预训练的 BERT 模型作为特征提取器,并结合多层感知器 MLP 和注意力机制来进行分类。

表 3 模型特征分布

模型	特 征					Ch-9	En-3
	内容	类别	情感	风格	情境	精确度	精确度
BERT	✓					0.895 6	0.806 3
BiGRU	✓					0.872 6	0.850 1
EANN	✓	✓				0.902 1	0.812 9
EDDFN	✓	✓	✓			0.887 4	0.799 8
MDFEND	✓	✓		✓		0.914 7	0.822 6
MMoE	✓	✓	✓			0.886 9	0.816 0
MoSE	✓	✓	✓			0.885 2	0.827 7
TextCNN	✓	✓	✓			0.880 8	0.841 6
DualEmo	✓	✓	✓	✓		0.898 9	0.804 4
M3FEND	✓	✓	✓	✓		0.895 1	0.822 6
Ours	✓	✓	✓	✓	✓	0.920 6	0.920 2

BiGRU 模型^[8]:结合了 BERT 和双向 GRU 的模型,用于中文和英文文本分类任务。根据数据集类型加载预训练的 BERT 模型,并冻结其参数,使用 BERT 的嵌入层进行嵌入、双向 GRU 提取文本特征、注意力机制对特征进行加权,将加权后的特征输入 MLP 进行分类,使用 Sigmoid 函数将输出转换为概率值。

EANN 模型^[28]:用于文本分类和领域分类任务的模型,结合了 BERT、卷积神经网络 CNN 和对抗网络。使用 BERT 提取文本特征、卷积层进行特征提取、将提取的特征输入 MLP 进行文本分类、使用反向梯度层进行对抗训练,并预测领域分类,返回文本分类的概率值和领域分类结果。

EDDFN 模型^[24]:用于文本分类和领域分类任务的模型,结合了 BERT、多层感知器 MLP 和对抗网络。使用 BERT 提取文本特征、使用注意力机制对特征进行加权、对每个类别的特征使用特定的 MLP 进行处理、使用共享的 MLP 处理特征、将共享特征和特定特征进行拼接、使用解码器进行重构特征、将拼接后的特征输入分类器进行文本分类、使用反向梯度层进行对抗训练,并预测领域分类。

MDFEND 模型^[29]:多领域联合学习模型,结合了 BERT、卷积神经网络 CNN、专家网络和注意力机制。使用 BERT 提取文本特征,并通过注意力机制加权、门控网络生成门控值,选择不同专家网络提取特征、将特征输入分类器进行分类。

MMoE 模型^[30]:多任务专家模型,结合了 BERT、MLP 和注意力机制,用于多头任务学习。使用 BERT 提取文本特征,并通过注意力机制加权、通过门控网络生成门控值,选择不同专家网络提取特征、使用任务头进行任务分类、返回任务分类的概率值。

MoSE 模型^[31]:多任务专家选择模型,结合了 BERT、LSTM 和注意力机制,用于多头任务学习。使用 BERT 提取文本特征,并通过注意力机制加权、通过

门控网络生成门控值,选择不同专家网络提取特征、使用任务头进行任务分类、返回任务分类的概率值。

TextCNN 模型^[32]:这是一个基于 TextCNN 的文本分类模型,结合了 BERT 和卷积神经网络 CNN。使用 BERT 嵌入层进行嵌入、使用卷积层提取文本特征、将提取的特征输入 MLP 进行分类、返回文本分类的概率值。

3.2.2 基于外部知识

DualEmo 模型^[1]:结合了 BERT、GRU 和情感特征的模型,使用新闻评论作为外部数据源,提取文本和评论情感特征并进行拼接,使用 BERT 提取文本特征、GRU 提取文本特征、注意力机制对特征进行加权,将文本特征和情感特征拼接,拼接后的特征输入 MLP 进行分类,使用 Sigmoid 函数将输出转换为概率值。

M3FEND 模型^[23]:多领域联合学习模型,结合了 BERT、卷积神经网络 CNN、多任务专家网络和注意力机制。提取外部数据的评论情感特征并进行拼接、BERT 提取文本特征,并通过注意力机制加权、基于外部知识库的领域记忆网络进行记忆增强,并获取一般和特定的领域嵌入、门控网络生成门控值,选择不同专家网络提取特征、逻辑神经网络对特征进行处理、将处理后的特征输入分类器进行分类。

3.3 实验设置

本文将数据集划分为 6:2:2 的比例,随机选择数据作为训练集、验证集、测试集,以便保持每个数据集的领域分布一致性。除了使用早期停止法以验证集的表现为准来防止过拟合外,不进行任何特定于数据集的调优操作。

参数设置本文借鉴了 Adam 算法^[33],用于更新模型参数,采用网格搜索方法对不同的参数进行调整。优化器的初始学习速率通过网格搜索方法从 $1e-6$ 到 $1e-2$ 进行调整,多头注意力机制中的头部数量从 1~10 进行调整,内存单元 Q 的数量从 5~50 进行调整。最小批量 batch size 的尺寸固定为 64。为了确保一个公平的比较,所有的 BiGRU 都设置为一层,隐藏层的大小为 300。所有模型中的卷积层配置了 5 个不同内核,卷积核大小分别是 {1,2,3,5,10},每个卷积核设置 64 个通道。对于本文方法中的所有全连接层的隐层维数设置为 386,采用 ReLU 作为激活函数。英文数据集和中文数据集的最大序列长度分别设置为 300 和 170。实验设置 k-means 算法类别个数设置为 [25, 150] 的数据序列,寻求最优的序列,本文最优序列是 $k=45$ 。epoch 从 25~150 之间调整,比较 10 个模型性能后,最终设置为 125 作为最优解。

3.4 性能比较(EQ1)

为了验证话题情境对证据的增强作用,对不同模

型添加话题情境证据增强步骤,对比前后结果,具体如表 4 所示。

易见,所有模型在引入新闻环境特征后,10 个基线模型的 AUC、Accuracy 和 $F1_{macro}$ 指标均有所提升,这表明模型在面对不同样本时能够更好地泛化,从而提升整体的分类准确性和综合性能。

基于内容的方法中 EANN 和 BiGRU 模型在引入话题情境特征后的性能提升更加明显。具体来说,EANN 模型在 Ch-9 数据集中引入话题情境特征后,AUC 提升幅度最大,达到 0.014 2,这一提升主要是因为 EANN 模型更加擅长处理包含背景信息的文本,而话题情境特征提供了丰富的背景信息,帮助 EANN 模型更好地理解 and 区分事件相关的正负样本,从而显著提升模型的 AUC 指标;BiGRU 模型在 En-3 数据集中引入话题情境特征后,Accuracy 和 $F1_{macro}$ 提升幅度最大,皆达到了 0.089 6,这是因为 BiGRU 模型能够有效利用上下文信息,而话题情境特征提供了丰富的事件背景和上下文信息,进一步提升了模型的分类性能和对正负样本的区分能力。由此得出结论:话题情境能够捕捉时间序列下话题情境和上下文信息,这也证明了话题情境的确有利用谣言的检测。

表 4 的预测结果也说明了话题情境能够起到对外部知识的放大作用,有利于系统性能的提升。遗憾的是提升效果不如基于内容的方法, $F1_{macro}$ 平均提升 0.9%,Recall、Precision 和 Accuracy 皆平均提升 0.8%,这可能是话题情境与外部知识源之间存在一定的信息覆盖造成的。

再看模型对数据集的依赖性,对比中英文数据集上的实验结果,发现模型性能提升幅度的不同。对于中文数据集 Ch-9,大部分模型在引入新闻环境特征后的性能提升幅度较大,AUC 和 $F1_{macro}$ 提升幅度尤其明显。而英文数据集 En-3,性能提升幅度也存在,但整体上可能略小于中文数据集,这种差异有可能与新闻内容编码的预训练模型有关。具体来说,对于中文数据集,使用的预训练模型是基于中文的 BERT 模型,新闻环境特征引入后,模型能够利用这些丰富的语义信息,显著提升分类性能。而对于英文数据集,使用的预训练模型是 RoBERTa-base,英文新闻文本可能结构更加直白,背景信息相对简洁,新闻环境特征的引入对性能提升的幅度略小。

正负样本分布不平衡和不同类别数据分布不平衡也可能引起提升幅度不同。具体来说,En-3 总体上存在明显的不平衡性,正样本远多于负样本,Ch-9 总体上正负样本相对平衡。模型在引入新闻环境特征后,AUC、 $F1_{macro}$ 和准确率均有所提升,说明话题特征能够帮助模型在一定程度上协调正负样本不平衡带来的性

能下降问题。Ch-9 中 Society 领域的数量远多于 Education 领域,En-3 中 GossipCop 领域的数量远多

于 PolitiFact 领域,模型的性能在引入话题环境特征后提升较为显著,这一结果也证明了我们的猜想。

表 4 基准模型在有无新闻环境的性能比较

模型		Ch-9 数据集			En-3 数据集		
		AUC 值	F_1 值	精确度	AUC 值	F_1 值	精确度
基于内容	BERT	0.954 3	0.895 6	0.895 6	0.784 9	0.693 3	0.806 3
	+Env	0.958 0	0.905 4	0.905 5	0.800 6	0.711 1	0.800 9
	BiGRU	0.943 1	0.872 5	0.872 6	0.868 5	0.762 3	0.850 1
	+Env	0.945 1	0.882 9	0.883 1	0.876 4	0.782 7	0.851 9
	EANN	0.964 4	0.902 1	0.902 1	0.837 7	0.737 7	0.812 9
	+Env	0.964 9	0.908 2	0.908 2	0.840 4	0.751 1	0.827 1
	EDDFN	0.949 7	0.887 4	0.887 4	0.758 9	0.651 3	0.799 8
	+Env	0.953 6	0.897 8	0.897 8	0.805 3	0.703 2	0.815 7
	MDFEND	0.971 2	0.914 7	0.914 7	0.864 7	0.764 8	0.822 6
	+Env	0.972 8	0.918 0	0.918 0	0.876 1	0.789 4	0.864 1
	MMoE	0.954 5	0.886 7	0.886 9	0.815 2	0.732 2	0.816 0
	+Env	0.957 3	0.897 7	0.897 8	0.846 6	0.751 7	0.826 8
	MoSE	0.950 3	0.885 2	0.885 2	0.833 7	0.727 9	0.827 7
	+Env	0.955 8	0.894 5	0.894 5	0.837 5	0.733 9	0.835 9
	TextCNN	0.953 0	0.880 7	0.880 8	0.862 7	0.767 6	0.841 6
	+Env	0.951 2	0.884 6	0.884 7	0.864 7	0.771 7	0.843 7
外部知识	DualEmo	0.963 2	0.898 8	0.898 9	0.780 6	0.688 3	0.804 4
	+Env	0.967 0	0.908 7	0.908 7	0.850 8	0.753 2	0.828 1
	M3FEND	0.960 6	0.894 8	0.895 1	0.874 6	0.784 6	0.822 6
	+Env	0.966 2	0.907 5	0.907 6	0.886 1	0.799 5	0.864 1
本文模型	Ours	0.970 9	0.915 0	0.915 0	0.883 9	0.722 4	0.844 2
	+Env	0.976 8	0.915 7	0.916 7	0.889 5	0.760 1	0.858 8

最后,本文的模型在引入新闻环境特征后,AUC、 $F1_{macro}$ 和准确率均达到最高值,显示了极高的性能。这表明新闻环境特征对提升模型的区分能力、综合性能和鲁棒性有重要作用。相比其他模型,本文的模型在处理包含丰富背景信息的新闻文本时,能够更好地利用这些信息,从而达到更高的性能水平。

3.5 变量评价(EQ2)

为了详细验证话题情境中对模型的贡献,进行了

两个消融实验,结果如表 5 和表 6 所示。

在这次实验中,没有立即使用虚假新闻检测模型,而是通过一个简单的逻辑回归分类器,分别输入 4 个环境感知向量中的其中一种、两种、三种或者四个都使用,看看它们在不配合假新闻检测器时是否可以工作。表 5 展示了两个数据集上的 AUC、 $F1_{macro}$ 和准确率的结果。

表 5 无模型的话题情境消融实验

模型	Ch-9 数据集			En-3 数据集		
	AUC 值	F_1 值	准确度	AUC 值	F_1 值	精确度
Env1	0.7767	0.694 2	0.803 7	0.799 1	0.671 6	0.804 8
Env2	0.770 2	0.639 5	0.804 9	0.763 6	0.639 3	0.780 8
Env3	0.774 8	0.636 8	0.804 7	0.798 7	0.639 9	0.732 4
Env4	0.770 9	0.603 5	0.799 4	0.715 1	0.625 5	0.791 2
Env1+Env2	0.793 6	0.701 1	0.815 2	0.803 6	0.702 0	0.821 0
Env1+Env2+Env3	0.819 1	0.723 5	0.826 8	0.825 5	0.737 3	0.818 9
Env1+Env2+Env3+Env4	0.822 1	0.733 6	0.839 4	0.827 2	0.741 3	0.819 4

单独使用任领域内话题情境特征时,每一个话题情境特征在没有假新闻检测器的情况下都具有一定的区

分能力,但效果有限。在 Ch-9 数据集中,AUC 值均在 0.770 2~0.776 7 之间, $F1_{macro}$ 在 0.603 5~0.694 2 之

间,准确率在 0.799 4~0.804 9 之间。在 En-3 数据集中,单独使用领域内话题情境特征时,AUC 值在 0.715 1~0.799 1 之间, $F1_{macro}$ 在 0.625 5~0.671 6 之间,准确率在 0.732 4~0.804 8 之间。

组合使用不同数量的话题情境特征后,可以观察到一个总体上升的趋势。在使用四个环境特征后,模型的性能显著提高。在 Ch-9 数据集中,使用所有四个环境特征 Env1+Env2+Env3+Env4 时,AUC 达到了 0.822 1, $F1_{macro}$ 为 0.733 6,准确率为 0.839 4。在 En-3 数据集中,使用所有四个环境特征时,AUC 达到了 0.827 2, $F1_{macro}$ 为 0.741 3,准确率为 0.819 4。多个环境特征的组合使用能够相互补充和增强,提升模型的整体性能。这说明每个环境特征都能提供独特的信息,对模型性能提升有积极作用。

但在某些情况下,添加更多的环境特征后,性能提升的幅度减小,表明存在边际效应递减的现象。例如,从 Env1 到 Env1+Env2+Env3 的提升较为显著,但从 Env1+Env2+Env3 到 Env1+Env2+Env3+Env4 的提升相对较小。

表 6 带模型的话题情境消融实验

模型	Ch-9 数据集			En-3 数据集		
	AUC 值	F_1 值	精确度	AUC 值	F_1 值	精确度
SEAFND w/o Env1	0.8922	0.870 2	0.903 2	0.893 2	0.873 1	0.904 3
SEAFND w/o Env2	0.899 6	0.883 3	0.916 7	0.900 4	0.883 7	0.907 7
SEAFND w/o Env3	0.904 9	0.891 7	0.917 0	0.914 7	0.893 3	0.917 4
SEAFND w/o Env4	0.912 8	0.909 0	0.910 6	0.928 2	0.910 5	0.919 6
Ours	0.925 3	0.921 2	0.920 6	0.933 3	0.928 0	0.920 2

3.6 不同 epoch 的影响 (EQ3)

在这一节中,研究 epoch 如何影响模型的性能。将 epoch 设置在 {25, 50, 75, 100, 125, 150} 范围内进行测试。图 2 和图 3 展示了模型在两种数据集上的表现。可以观察到,epoch 显著影响了模型性能。




图2 CH-9数据集中不同 epoch 对模型的影响

在 Ch-9 数据集中,随着 epoch 数量的增加,系统性能不断提升。当 epoch 数量达到 125 时,模型的准确率最高。当继续增加时,模型性能逐渐下降。当 epoch 过大时,模型可能会过拟合训练数据,从而导

致泛化能力下降,各指标下降,因此我们将 epoch 设置为 125,作为最佳参数。

通过表 5 显示的结果,证明了话题情境的作用,下面将不同的话题情境与模型结合验证情境与模型之间是否存在互补。这里我们使用的模型结合了 BERT、双向 GRU 和风格特征的文本分类模型。从模型中分别删除 Env1、Env2、Env3 和 Env4 后,观察到模型性能的变化,表明这四种环境特征在检测过程中发挥着互补的作用。以下是对表 6 中结果的详细分析:

Env1 是对模型性能最重要的话题情境特征。删除 Env1 后,模型的 AUC、 $F1_{macro}$ 和准确率均显著下降,这也表明了 Env1 在捕捉话题情境信息方面起着关键作用。删除 Env2 和 Env3 这两个特征中后发现,系统性能明显下降,同样表明它们能够增强模型对新闻环境信息的理解。相对而言,Env4 对系统的影响较小,但也会导致性能下降。

四种环境特征在检测过程中具有互补作用。结合使用所有环境特征时,模型性能达到最佳,说明每个特征都提供了独特的信息,这些信息相互补充,共同提升了模型的整体性能。

致泛化能力下降,各指标下降,因此我们将 epoch 设置为 125,作为最佳参数。




图3 EN-3数据集中不同 epoch 对模型的影响

在 En-3 数据集中,epoch 从 25 逐渐增加到 45 这个过程中,可能是因为数据集的问题,性能没有出现明显的提升。随着 epoch 的增加,系统性能也随着 epoch 数量的增加而逐渐提升,当 epoch 位于 100~125 之间时,系统性能达到峰值。当继续增加 epoch 时,模型性能将会缓慢下降,相比于 Ch-9 数据集,下降的速度较慢。En-3 数据集的规模较大,不易出现过拟合,所以即使 epoch 过大,性能下降的速度也较慢,因此我们将

epoch 设置为 100, 作为最佳参数。

4 结 语

为了解决谣言检测过程中证据滞后的问题, 本文提出一种基于情境感知的网络谣言检测方法。首先利用拉普拉斯谱聚类对领域内和领域间的话题情境聚类, 依据领域内和领域间的话题分布, 构建四个话题情境, 用于捕捉话题的热度和新颖度, 并融合新闻文本、风格特征、情感等特征设计一个情境感知模型, 用于现实谣言的早期检测。最后在中文数据集 Ch-9 和英文数据集 En-3 的实验验证本文方法, 实验结果表明, 话题情境有助于谣言的早期发现, 尤其在证据稀少的情境下, 话题情境可以起到证据增强的作用。

尽管本文方法在谣言检测方面有了提升, 但是本文的研究仅关注了文本内容信息, 而对于谣言传播结构, 网民面对谣言时的信息行为以及多模态特征的研究却没有涉及, 这些研究内容将是我们下一步的重点研究内容。

参 考 文 献

- [1] Zhang X, Cao J, Li X, et al. Mining dual emotion for fake news detection [C]//Proceedings of the International Conference of World Wide Web, 2021: 3465-3476.
- [2] Hu L, Yang T, Zhang L, et al. Compare to the knowledge: Graph neural fake news detection with external knowledge [C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing, 2021: 754-763.
- [3] Guo H, Zeng W, Tang J, et al. Interpretable fake news detection with graph evidence [C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 2023: 659-668.
- [4] Ma J, Gao W, Wong K F. Detect rumors on twitter by promoting information campaigns with generative adversarial learning [C]//Proceedings of the International Conference of World Wide Web, 2019: 3049-3055.
- [5] Alonso M A, Vilares D, Carlos Gómez-Rodríguez, et al. Sentiment analysis for fake news detection [J]. Electronics, 2021, 10 (11): 1348.
- [6] Wu J, Hooi B. Fake news in sheep's clothing: Robust fake news detection against llm-empowered style attacks [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/2310.10830>.
- [7] 曾江峰, 程 征, 黄泳潼, 等. 融合 BERT 和主题模型的谣言检测方法 [J]. 情报科学, 2024, 42 (2): 12-23.
- [8] Ma J, Gao W, Mitra P, et al. Detecting rumors from microblogs with recurrent neural networks [C]//Proceedings of the 25th International Joint Conference on Artificial Intelligence, 2016: 3818-3824.
- [9] Chen T, Li X, Yin H, et al. Call attention to rumors: Deep attention based recurrent neural networks for early rumor detection [C]//Trends and Applications in Knowledge Discovery and Data Mining: PAKDD 2018 Workshops, BDASC, BDM, ML4Cyber, PAISI, DaMEMO, Melbourne, VIC, Australia, June 3, 2018, Revised Selected Papers 22. Springer International Publishing, 2018: 40-52.
- [10] 王 昊, 龚丽娟, 周泽聿, 等. 融合语义增强的社交媒体虚假信息检测方法研究 [J]. 数据分析与知识发现, 2023, 7 (2): 48-60.
- [11] 安 全, 徐国天. 基于领域信息和自定义门控网络的网络谣言实时检测方法 [J]. 情报杂志, 2024, 43 (10): 127-133, 175.
- [12] Kaliyar R K, Goswami A, Narang P. Fakebert: Fake news detection in social media with a bert-based deep learning approach [J]. Multimedia Tools and Applications, 2021, 80 (8): 11765-11788.
- [13] Wu J, Li S, Deng A, et al. Prompt-and-align: Prompt-based social alignment for few-shot fake news detection [C]//Proceedings of the 32nd ACM International Conference on Information and Knowledge Management, 2023: 2726-2736.
- [14] Li H, Yang W, Wang H, et al. FSRD: Few-shot fuzzy rumor detection system with stance-enhanced prompt learning [J/OL]. Soft Computing, 2024: 1-15 [2024-08-10]. <https://link.springer.com/article/10.1007/s00500-023-09439-4>.
- [15] Sun M, Zhang X, Ma J, et al. Inconsistent matters: A knowledge-guided dual-consistency network for multi-modal rumor detection [J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 35 (12): 12736-12749.
- [16] Amer E, Kwak K S, El-Sappagh S. Context-based fake news detection model relying on deep learning models [J]. Electronics, 2022, 11 (8): 1255.
- [17] Lin H, Yi P, Ma J, et al. Zero-shot rumor detection with propagation structure via prompt learning [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/2212.01117>.
- [18] 汪子航, 言鹏伟, 蒋卓人. 基于可解释图神经网络模型的社交媒体谣言识别研究 [J]. 情报学报, 2023, 42 (11): 1369-1381.
- [19] Zhang K, Yu J, Shi H, et al. Rumor detection with diverse counterfactual evidence [C]//Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2023: 3321-3331.
- [20] 朱 贺. 融合信息对抗及混合特征表示的社交网络谣言检测方法 [J]. 情报杂志, 2024, 43 (2): 118-127.
- [21] Sheng Q, Cao J, Zhang X, et al. Zoom out and observe: News environment perception for fake news detection [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/2203.10885>.
- [22] Przybyla P. Capturing the style of fake news [EB/OL]. [2024-08-10]. <https://aaai.org/papers/00490-capturing-the-style-of-fake-news/>.
- [23] Zhu Y, Sheng Q, Cao J, et al. Memory-guided multi-view multi-domain fake news detection [J/OL]. IEEE Transactions on Knowledge and Data Engineering, 2022: 1-14 [2024-08-10]. <https://dl.acm.org/doi/10.1109/TKDE.2022.3185151>.
- [24] Silva A, Luo L, Karunasekera S, et al. Embracing domain

(下转第 50 页)

- novation as U.S. exits top ten [EB/OL]. [2024-02-18]. <https://www.bloomberg.com/news/articles/2021-02-03/south-korea-leads-world-in-innovation-u-s-drops-out-of-top-10>.
- [21] Kevin D. U.S. suffers greatest global decline in trust [EB/OL]. [2024-02-19]. <https://www.usnews.com/news/best-countries/articles/2020-01-15/us-trustworthiness-rating-dives-in-2020-best-countries-report>.
- [22] Richard W, Janell F, Mara M. U.S. image plummets internationally as most say country has handled coronavirus badly [EB/OL]. [2024-02-19]. <https://www.pewresearch.org/global/2020/09/15/us-image-plummets-internationally-as-most-say-country-has-handled-coronavirus-badly/>.
- [23] Ronald K, Jennifer S. How not to ensure credibility with allies [EB/OL]. [2024-02-20]. <https://mwi.westpoint.edu/not-ensure-credibility-allies/>.
- [24] Amanda M. Biden vows to restore U.S. alliances and lead with diplomacy in his first foreign policy address [EB/OL]. [2024-02-21]. <https://www.cnn.com/2021/02/04/biden-vows-to-restore-alliances-in-first-foreign-policy-address.html>.
- [25] Eli S, David C. Declaring 'America is back,' Biden tries to regain Europe's trust [EB/OL]. [2024-02-21]. <https://www.latimes.com/politics/story/2021-02-19/declaring-america-is-back-biden-tries-to-regain-europes-trust>.
- [26] Lauren S. How Biden can improve European relations while pivoting to Asia [EB/OL]. [2024-02-22]. <https://thebulletin.org/2021/11/how-biden-can-patch-european-relations-while-pivoting-to-asia/>.
- [27] Richard A. Intelligence and international security [EB/OL]. [2024-02-22]. <https://oxfordre.com/internationalstudies/display/10.1093/acrefore/9780190846626.001.0001/acrefore-9780190846626-e-222>.
- [28] Ariel S. Toward a quadrilateral intelligence sharing network? [EB/OL]. [2024-02-24]. <https://thediplomat.com/2022/01/toward-a-quadrilateral-intelligence-sharing-network/>.
- [29] Dun M. Intelligence cooperation meets international studies theory: Explaining canadian operations in castro's cuba [J]. Intelligence and National Security, 2009, 24(1): 119-138.
- [29] Julian B, David S. Accurate U.S. intelligence did not stop Putin, but it gave Biden big advantages [EB/OL]. [2024-02-24]. <https://www.nytimes.com/2022/02/24/world/europe/intelligence-putin-biden-ukraine-leverage.html>.
- [31] Reuben S. The strategic case for New Zealand to join AUKUS [EB/OL]. [2024-02-26]. <https://thediplomat.com/2023/04/the-strategic-case-for-new-zealand-to-join-aukus/>.
- [32] Mark Christian Soo. Reforming Japanese intelligence agencies [EB/OL]. [2024-03-04]. <https://greydynamics.com/japanese-intelligence-agencies-reforms/>.
- [33] Christopher P, Angela M, Gene G, et al. Chasing multinational interoperability: benefits, objectives, and strategies [EB/OL]. [2024-03-14]. https://www.rand.org/content/dam/rand/pubs/research_reports/RR3000/RR3068/RAND_RR3068.pdf.
- [34] Nike C. US voices concerns over China's counterespionage push [EB/OL]. [2024-03-16]. <https://www.voanews.com/a/us-voices-concerns-over-china-s-counterespionage-push-/7209514.html>.
- (责编:王育英;校对:贺小利)
- +++++
- (上接第120页)
- differences in Fake News: Cross-domain Fake News detection using multi-modal data [EB/OL]. [2024-08-10]. <https://ojs.aaai.org/index.php/AAAI/article/view/16134>.
- [25] Shu K, Mahudeswaran D, Wang S, et al. Fakenewsnet: A data repository with news content, social context, and spatiotemporal information for studying fake news on social media [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/1809.01286>.
- [26] Li Y, Jiang B, Shu K, et al. MM-Covid: A multilingual and multimodal data repository for combating covid-19 disinformation [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/2011.04088>.
- [27] Devlin J, Chang M W, Lee K et al. Bert: Pre-training of deep bidirectional transformers for language understanding [EB/OL]. [2024-08-10]. <https://aclanthology.org/N19-1423/>.
- [28] Wang Y, Ma F, Jin Z, et al. Eann: Event adversarial neural networks for multi-modal fake news detection [C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018: 849-857.
- [29] Nan Q, Cao J, Zhu Y, et al. Mdfend: Multi-domain fake news detection [C]//Proceedings of the 30th ACM International Conference on Information & Knowledge Management, 2021: 3343-3347.
- [30] Ma J, Zhao Z, Yi X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts [C]//Proceedings of the 24th ACM Sigkdd International Conference on Knowledge Discovery & Data Mining, 2018: 1930-1939.
- [31] Qin Z, Cheng Y, Zhao Z, et al. Multitask mixture of sequential experts for user activity streams [C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2020: 3083-3091.
- [32] Kim Y. Convolutional neural networks for sentence classification [C]// Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, Oct, 2014: 1746-1751.
- [33] Kingma D P. Adam: A method for stochastic optimization [EB/OL]. [2024-08-10]. <https://arxiv.org/abs/1412.6980>.
- (责编:王育英;校对:刘影梅)